

课程笔记

江鋆晨：大模型记忆，KV Cache，清华姚班，CMU，教授，开源，视频流媒体

五道口纳什 & Codex

2026 年 7 月 18 日



视频作者/频道：月球大叔

发布日期：2025 年 7 月

视频时长：2 小时 25 分钟

视频链接：<https://www.bilibili.com/video/BV1x2EQ6BE1g/>

目录

1	从姚班到 CMU：学术成长之路	2
1.1	数学竞赛、保送与姚班	2
1.2	选择 CMU 与张辉导师	2
1.3	Ion Stoica 与”放弃的艺术”	2
1.4	本章小结	3
2	视频流媒体的黄金年代	3
2.1	HTTP 成为流媒体协议的偶然革命	3
2.2	从野蛮生长到系统化研究	4
2.3	从流媒体到 KV Cache：三维数据的暗线	4
2.4	本章小结	5
3	存储价格的暴涨与 KV Cache 的浮现	5
3.1	为什么存储会在 AI 时代成为问题	5
3.2	KV Cache 是模型的”记忆”	6
3.3	本章小结	6
4	在学术与工业之间穿梭	6
4.1	写产品代码的那段经历	6
4.2	LMCache 的诞生	6
4.3	本章小结	7
5	判断力：高价值问题、科学史与学生	7
5.1	如何识别高价值问题	7
5.2	多读科学史	7
5.3	如何找学生	8
5.4	本章小结	8
6	All in ChatGPT：范式的跳转	8
6.1	从流媒体到大模型：一个人生转折	8
6.2	为什么选择做基础设施而非模型	9
6.3	本章小结	10
7	深入理解 KV Cache	10
7.1	KV Cache 是什么	10
7.2	Prefill vs Decode：算力分配的”反直觉”真相	11
7.3	LMCache 的设计哲学	11
7.4	为什么开源是必须的	12
7.5	章末小结	12
8	Agent 与模型原生记忆	12
8.1	Agent 为什么需要更好的记忆管理	12
8.2	模型原生记忆 vs 文本记忆	13

8.3	从”记下来”到”理解记忆”	13
8.4	章末小结	14
9	创业：融资、团队与现实扭曲力场	14
9.1	2000 万美金融资背后的信号	14
9.2	没有竞争对手时的孤独	14
9.3	现实扭曲力场：正向解读	15
9.4	师生关系与创业团队	15
9.5	章末小结	16
10	未来基础设施与职业建议	16
10.1	OpenAI API = 新时代的 IP 层	16
10.2	不同年龄段的职业建议	16
10.3	章末小结	17
11	总结与延伸	17
11.1	讲者的核心脉络	17
11.2	结构化的核心洞察	18
11.3	职业判断力的底层逻辑	18
11.4	拓展阅读	18

1 从姚班到 CMU：学术成长之路

1.1 数学竞赛、保送与姚班

江鋆晨的学术起点始于数学竞赛。2006 年，他获得数学竞赛保送资格，2007 年进入清华大学数理基科班——数学与物理的交叉培养项目。然而，在入学后他发现基科班人数众多，恰好此时计算机系姚期智先生创办了一个新班级，入学考试只考数学竞赛内容，他便顺理成章地考入了姚班。

姚班当年的独特氛围

姚班在十年前并不是以 AI 为核心——那个年代深度学习远未进入主流视野。当时的姚班探索的是云计算、分布式系统等方向。江鋆晨回忆道，他加入的实验室做的是网络安全，这给他后来的学术选择埋下了伏笔：“我特别不喜欢安全，因为安全是禁止你做什么的东西——你得严谨地证明某个东西一定安全，而我更喜欢突破限制。”

在这个早期阶段，他遇到了对他影响深远的导师刘斌老师。”刘斌老师给学生非常多的自由，非常纯粹。你跟他谈研究，他会非常开心——你跟他说得越多，他越开心。”这种氛围让江鋆晨在清华期间建立起对网络系统的浓厚兴趣。

1.2 选择 CMU 与张辉导师

博士申请时，多数给他发 offer 的地方都是做安全的导师——因为他们看到他的安全背景，以为他会继续走安全路线。但 CMU 是 committee 录取，不指定导师，给了他重新选择的空间。

在 CMU 的开放日，经学长建议，他联系了张辉老师。当时张辉已经在硅谷创业多年（2004 年就开始开公司），正准备离开学术界。但张老师做了一件让江鋆晨至今印象深刻的事：

因材施教的导师艺术

张辉老师把他叫到加州，让他在会议室的板前讲了一通自己想做什么。”我当时非常激动，说了我想做这个、想做那个。张老师听了半天，我猜他心里在想着‘这是什么东西，做不了’。但他让我讲的过程，是因为他觉得‘我只听你讲，才能知道你想做什么，你喜欢什么样的东西’。”后来证明，张老师非常能因材施教——他甚至能让一个学生去做自己本不喜欢的方向，却让学生觉得”这就是我特别喜欢做的事情”。

1.3 Ion Stoica 与”放弃的艺术”

在 CMU 期间，另一位让他深受触动的人物是 Ion Stoica——著名的系统研究者，Spark 的导师之一。江鋆晨对 Stoica 的评价集中在一种罕见的能力：

知道何时放弃——Ion Stoica 的学术生涯

Stoica 从路由（routing）和 QoS 做到最高潮时说”不做就不做了”，转向 P2P；P2P 在研究最高潮时又说”不做就不做了”，转向大数据（Big Data）；大数据做到最高潮时又”不做就不做了”，开始做 AI Serving。这种能力的关键不在于追逐热门方向，而在于判断”接下去五年什么东西最重要”。

”这种放弃的能力好强大呀。”——主持人月球大叔如此感叹。这与上一期嘉宾分享的”多放弃才能有更多的获得”形成了呼应。

1.4 本章小结

江鋆晨的学术道路体现了两个关键线索：一是从数学竞赛到姚班到 CMU 的”自由生长”——导师给予的空间比指导更重要；二是对”突破限制”的持续偏好——从抗拒安全研究的”禁止思维”到选择网络系统这个可以自由构建的领域。Ion Stoica 的”放弃的艺术”则给出了一个更高的参照：真正的判断力不在于抓住什么，而在于知道何时放手。

2 视频流媒体的黄金年代

2.1 HTTP 成为流媒体协议的偶然革命

2010 年左右，视频流媒体领域发生了一个类似今天 AI 时刻的拐点。江鋆晨用与当下完全对称的比喻来描述：

流媒体的”Internet Moment”

2010 年的媒体公司面临的情况与今天每个公司要有 AI Strategy 如出一辙：当时的每一个媒体公司都需要一个 Video Streaming Strategy。Netflix、Hulu、HBO、BBC 这些公司突然意识到，自己有视频内容，可以直接通过宽带网络传给用户。但关键问题是：怎么做？之前从来没有一套专门为流媒体设计的系统。已有的只有 HTTP——为网页而生的协议。所有网络运营商都支持 HTTP，而 HTTP 在高带宽用户上居然跑得起来。于是所有公司开始野蛮生长，用 HTTP 传输视频。这场自发的革命，与今天大模型领域的爆发有着惊人的同构性。



图 1: 视频流媒体 HTTP 革命的类比：每个媒体公司都需要一个 Streaming Strategy ¹

¹视频画面时间区间：00:26:00–00:32:00。

2.2 从野蛮生长到系统化研究

正因为工业界在野蛮生长，出现了大量未经系统研究的协议和传输方式。江鋆晨的博士研究方向正是基于这一观察产生：

研究机会的诞生

”这些所有视频传输的格式和协议，没有研究人员想过：这些协议会对网络有多大的影响？如何用有原则的方法、更好的抽象和算法去优化这一类野蛮生长出来的系统？”张辉老师的公司当时正好在做流媒体系统，先看到了这个需求，但公司里的工程师没有时间做系统化研究——这就是一个典型的学术研究 gap。

Adaptive Bitrate (ABR) 算法成为当时的热门研究方向。视频播放器需要根据网络状况动态调整清晰度——这是一个在不确定网络条件下做连续决策的问题。江鋆晨在这个领域发表了多篇论文，积累了系统化研究网络协议的经验。

2.3 从流媒体到 KV Cache：三维数据的暗线

一个饶有趣味的观察贯穿了整个对话：视频数据和 KV Cache 在本质上有共同之处——都是三维数据。江鋆晨在采访中提到，”同时视频跟 KV Cache 其实都是三维的。”视频数据是时间 $\times$ 空间（宽 $\times$ 高）的三维张量，KV Cache 是层数 $\times$ 序列长度 $\times$ 隐藏维度的三维矩阵。这种对高维数据流的处理经验，为他后来转向大模型基础设施埋下了潜意识的基础。



图 2: ABR 算法：在不确定网络条件下动态决策²

²视频画面时间区间：00:32:00–00:37:00。

2.4 本章小结

十年视频流媒体的研究给了江鋆晨两样东西：一是对“野蛮生长中的系统可以从外部做结构化优化”的信念——HTTP 流媒体最初混乱无序，但研究者可以通过建模和算法使其更可持续；二是对数据流的直觉——视频是时空三维数据，而 KV Cache 是层序维三维数据。这种跨领域的迁移能力，后来在他转向大模型基础设施时发挥了关键作用。

3 存储价格的暴涨与 KV Cache 的浮现

3.1 为什么存储会在 AI 时代成为问题

对话以一个“劲爆话题”开场：存储价格暴涨。江鋆晨给出了一个反直觉的分析框架——在 AI 时代，所有人的注意力都在算力（Compute）上，没有人考虑存储的能力和容量。但算力越多，对存储的要求也会越多。

算力与存储的耦合关系

算力越多 → 模型推理中产生的中间数据（KV Cache）越多 → 需要存储的数据越多 → 存储需求增加 → 存储价格上涨（供需失衡）。这个链条中，关键的一环是 KV Cache——模型在计算和运行过程中生成的数据，是目前对存储压力非常大的一个原因。

江鋆晨半开玩笑地说：“这有可能是我们导致价格上涨的原因之一。”这句话背后的实际含义是：LMCache 团队是最早系统性研究 KV Cache 存储问题的团队之一——他们既看到了问题，也在推动解决这个问题。



图 3: 存储价格暴涨的背后逻辑：算力增加 → KV Cache 增加 → 存储需求激增³

³视频画面时间区间：00:00:00–00:08:00。

3.2 KV Cache 是模型的”记忆”

在对话的早期，江鋆晨就抛出了一个关键定义——KV Cache 是模型的记忆。这不是一个比喻，而是一个技术事实：

KV Cache

模型在”阅读”一段文本时，会将输入转化为内部表示——Key-Value 矩阵。这个矩阵就是模型对这段文本的”理解”或”记忆”。如果这个记忆被丢弃，下次模型看到同样或相似的文本时，必须从头重新计算。KV Cache 的本质就是把模型的”理解过程”的中间产物保存下来，避免重复劳动。

这与人阅读一本书的过程类同：你读完一本书后，脑子里有了对书的理解（记忆），下次别人问你这本书的内容时，你不需要重新翻一遍——可以直接从记忆中提取。模型也应该如此。

3.3 本章小结

存储暴涨不是简单的供需问题，而是 AI 时代结构性变化的一部分。当所有人都盯着算力时，存储作为”看不见的基础设施”正成为瓶颈。KV Cache 既是造成存储压力的原因，也是解决问题的钥匙——因为一旦能被有效存储和管理，它就能成为模型的持久记忆，而非一次性消耗品。

4 在学术与工业之间穿梭

4.1 写产品代码的那段经历

博士毕业后，江鋆晨有一段在工业界写产品代码的经历。这段经历对他的研究产生了意想不到的影响：

工业界的真实问题是最好的 PhD 课题来源

”在工业界直接去写产品代码、做工程——那次对我研究的帮助是最大的。”为什么？因为工业界工程师不会从论文里找问题来做——他们面对的是真实的用户痛点、真实的系统瓶颈。而这些真实问题，恰恰是最有研究价值的学术课题。

”工程师们给我的问题，后来变成了我的 PhD 研究课题。”这种”从工业界获取问题 → 在学术界做系统化研究 → 最终回到工业界落地的循环，是他整个职业生涯的核心模式。

4.2 LMCache 的诞生

LMCache 最初的起点是一个学术项目。在 ChatGPT 爆发后，江鋆晨和他的学生开始思考一个问题：为什么每次向大模型提问相同的上下文，它都要重新计算一遍？是否存在一种方法，能把模型的计算结果以”记忆”的形式保存下来？

从学术项目到开源项目的跃迁

LMCache 作为学术项目开始后，团队越来越清楚地意识到：要做的事情太大了——要给整个工业界做一套新的基础设施，还要把研究 idea 源源不断输送到工业界——这绝对不是学术界或一个开源项目能单独完成的事情。”必须得拉投资，必须得开公司，必须得让工业界一起参与进来。”于是，学术项目自然演化成了创业公司 TensorMesh。



图 4: LMCache: 从学术项目到开源到创业公司的演化路径⁴

4.3 本章小结

江鋆晨的职业生涯有一个稳定的模式：从工业界的真实问题出发，在学术界做系统化、原理性的研究，再将研究成果以开源和创业的形式推回工业界。这种“工业-学术-工业”的闭环，使他的研究始终扎根于真实需求，而非论文写作的自我循环。

5 判断力：高价值问题、科学史与学生

5.1 如何识别高价值问题

当被问到“如何判断什么是值得投入的高价值问题”，江鋆晨的回答出人意料地务实：

判断高价值问题的三个原则

1. **不要跟风**：当所有人都涌入一个方向时，那里大概率已经没有高价值问题留给新进入者了。
2. **寻找结构性缝隙**：在工业界“已经在做但还没做好”和学术界“还没人研究”之间，存在大量高价值问题。这些问题工业界没时间系统化，学术界还没发现。
3. **看底层规律而非表面热度**：视频流媒体的崛起不是因为某家公司做了什么，而是因为宽带普及这个底层变量——AI时代同理。

5.2 多读科学史

江鋆晨反复强调科学史的重要性，这在外人看来似乎与做技术创业无关，但他有自己的理由：

⁴视频画面时间区间：00:44:00-00:55:00。

为什么技术人要读科学史

科学史让你看到技术演化的底层规律。比如：

- HTTP 成为流媒体协议不是因为它“最好”，而是因为它是唯一所有人都支持的协议——这与今天 OpenAI API 成为事实标准的逻辑一脉相承
- 每一次技术浪潮都有“被遗忘的方向”——它们不是错了，而是早了（timing matters more than correctness）
- 真实的技术演进从来不是线性的——读历史可以培养对“非线性”的直觉

5.3 如何找学生

作为芝加哥大学的教授，江鋆晨的招人标准同样体现了他的价值观。他不看重简历上的“亮点词”，而是看重：

- 是否真正有热情——不是“应该做 AI”而是“忍不住要做 AI”
- 是否能独立思考——你的想法来自哪里，是不是你自己的
- 是否有好奇心——你会不会因为一个问题有趣而去研究它，不管它当下火不火

5.4 本章小结

判断力不是某种玄学能力，而是可以被训练的思维方式：多读历史知道什么规律在重演，多接触工业界知道什么是真实的，多看底层变量知道什么变化是结构性的。找学生也是如此——与其找“符合标准”的人，不如找有内在驱动力的人。

6 All in ChatGPT：范式的跳转

6.1 从流媒体到大模型：一个人生转折

2012 年 AlexNet 出现时，深度学习只是计算机视觉领域的一个小众方向。江鋆晨回忆道，那时清华孙茂松老师的一个博士生出去开会回来，像讲新闻一样告诉大家：“深度学习这个东西以后是未来，我们得做。”而当时大多数人还在用 SVM 和 Linear Regression 入门机器学习，“大家都不知道深度学习是什么”。

真正让他做出人生中最重大转向的，是 ChatGPT 的出现。这个瞬间，他看到了一个与视频流媒体完全对称的历史机遇：

ChatGPT 作为”Internet Moment”

ChatGPT 之于大模型时代，就如同 2010 年 HTTP 视频流媒体的爆发之于网络时代。两个时刻共享同样的特征：

- 一个新技术突然证明自己能用（且足够好）
- 所有公司立刻意识到” 我们必须有这个东西”
- 但没有人知道怎么正确地、可持续地做
- 研究者有机会在野蛮生长中建立系统化的方法论

正是基于这个判断，他决定放弃做了十年的视频流媒体领域，全身心投入大模型基础设施。”这不是跟风，而是重复已经验证过一次的模式。”



图 5: All in ChatGPT: 从流媒体到大模型基础设施的范式跳转⁵

6.2 为什么选择做基础设施而非模型

很多人会问：既然看到了 ChatGPT 的浪潮，为什么不自己做模型？江鋆晨的回答反映了典型的系统研究者思维：

做模型 vs 做基础设施

做模型的公司已经有很多了，而且竞争极其激烈。但所有模型都需要运行，运行就需要基础设施。KV Cache 是所有 Transformer 模型都共有的组件——不管你是谁家的模型，都要面临同样的问题。这就像在视频流媒体时代，不去做 Netflix 那样的内容公司，而是去研究所有视频公司都需要的传输协议。这是一个更宽、更深、也更持久的机会。

⁵ 视频画面时间区间：01:05:00–01:12:00。

6.3 本章小结

“All in ChatGPT” 不是一个投机决策，而是一个模式识别的结果。十年前他在视频流媒体爆发时进入，看到了”野蛮生长中的系统化研究机会”；十年后他在大模型爆发时看到了完全相同的机会结构。这种模式识别能力，比任何具体的技术知识都更为稀缺。

7 深入理解 KV Cache

7.1 KV Cache 是什么

这是视频中最技术的部分。江鋆晨用一个直观的类比来解释 KV Cache 的工作原理：

KV Cache 的直觉理解——程序员读代码

你是一个非常聪明的程序员，我给了你一个程序让你去分析，告诉你说”能不能在这个程序里面加一个新的功能”。

你做的第一件事情是肯定得先读这个程序——模型也是一样。人会把程序理解成脑子里能记住的结构和记忆，模型也有这样的记忆——这个记忆就是 KV Cache。它是一大坨浮点数，是一个三维矩阵，但这是模型”记住”新知识的方式。

下一次如果我再让你在这个程序上加另一个功能，如果你把之前读程序的记忆给忘了（现在很多模型确实在干这件事），你就得从头再读一遍——那 90% 的输入都是同一个程序，为什么要重复计算呢？



图 6: KV Cache 在推理流程中的位置：Pre-fill（输入处理）→ KV Cache 存储 → Decode（输出生成）⁶

⁶视频画面时间区间：01:21:00–01:28:00。

7.2 Prefill vs Decode: 算力分配的”反直觉”真相

江鋆晨提出了一个非常重要的观察——绝大多数人对模型推理的算力分配存在误解：

算力分配的反直觉真相

人的感官：你盯着屏幕等模型输出，感觉 90% 的时间都在等它生成（Decode）。

实际算力：90% 的算力花在了输入处理（Prefill）上。

为什么：在 Agent 场景中，输入往往是几万、几十万甚至几百万 Token（上下文 + 工具调用结果 + 历史记录），而输出通常只有几千 Token。”你现在的输出永远都会变成以后的输入”——这句话是对这个现象最精辟的概括。

含义：硬件公司优化 Decode 速度（因为用户能感知到），但真正的算力瓶颈在 Prefill——这正是 KV Cache 发力的地方。如果你能复用之前 Prefill 的计算结果（即 KV Cache），就能跳过 90% 的重复计算。




图 7: 模型推理的两阶段：Prefill 消耗 90% 算力处理输入，Decode 消耗 10% 算力生成输出。KV Cache 在 Prefill 阶段生成，可供后续复用

7.3 LMCache 的设计哲学

LMCache 要做的事情，可以概括为一个词：解耦。

LMCache 的核心设计哲学——强解耦的 KV Cache Layer

在现有的推理架构中，KV Cache 通常被强绑定到具体的推理引擎上（比如 vLLM 的 PageAttention 管理的内存）。这种绑定有几个问题：

- 你想换推理引擎，KV Cache 的格式和管理就得跟着变
- 你想把 KV Cache 存到不同的存储介质（DRAM、SSD、远程存储），没有统一接口
- 你想在不同模型之间共享或迁移 KV Cache，几乎不可能

LMCache 的答案：做一个独立的、强解耦的 KV Cache Layer，让它处于推理引擎和存储系统之间。不管用什么引擎（vLLM、SGLang、TensorRT-LLM）、什么存储（本地 DRAM、NVMe、远程对象存储），LMCache 提供统一的接口来管理和传输 KV Cache。




图 8: LMCache 的架构定位：在推理引擎层和存储介质层之间，提供强解耦的统一 KV Cache 管理

7.4 为什么开源是必须的

江鋆晨在采访中坦诚地讨论了开源的风险。做开源项目的公司很多，但真正成功的很少——Spark 是直接从工业界需求中生长出来，硬生生干掉了当时的闭源方案。LMCache 也走了这条路：

开源的哲学

“开源这件事情就是让大家有选择。最大的需求就是：我用你的东西，也可以用别人的东西，我随时可以在各个层上换选择。”做解耦的 KV Cache Layer，开源是天然的选择——因为它要成为所有引擎和所有存储之间的“中间人”，闭源会破坏这个定位。

“如果说某一家公司更愿意接入你们这个标准，那么可能的话，其他的模型厂商就更愿意用这一家的存储介质或推理引擎。”这种网络效应，正是 LMCache 试图通过开源建立的标准地位。

7.5 章末小结

KV Cache 不仅仅是一个技术优化手段，它代表了一种看待模型计算的新范式：将模型的计算结果视为一种可复用、可管理、可优化的资产 (asset)，而非一次性消耗品。从 Prefill 到 Decode 的算力分配真相，到 LMCache 的强解耦架构，江鋆晨的核心论点是：KV Cache 是模型推理的“记忆层”，而这个记忆层需要独立的基础设施来管理。

8 Agent 与模型原生记忆

8.1 Agent 为什么需要更好的记忆管理

Agent 的本质是“模型与环境的多次交互”。与单次对话不同，Agent 在完成一个任务的过程中，需要和外部环境（工具、数据库、其他 Agent）反复交互：

Agent 场景对记忆管理的挑战

- 交互次数增多 → 需要记住的上下文激增
- 记忆不是简单的堆积——需要不停地 shuffle、取出最相关的部分
- 越复杂、越长的任务，记忆管理的方式也需要越复杂
- 传统方案用“人话”管理记忆（存文本、Code、图片），但模型需要的是“模型可以理解的记忆”

8.2 模型原生记忆 vs 文本记忆

江鋆晨提出了一个关键区分——当前绝大多数记忆管理系统以”人能理解的形式”管理记忆（存储文本、对话历史等），然后在每次调用时把这些文本重新输入给模型。但 LMCache 管的不是这些文本，而是”文本在人话层面的镜像”——即文本经过模型处理后的 Key-Value 表示：

模型原生记忆的优势

- **直接可用**：KV Cache 的格式是模型神经网络的内部表示，模型可以直接”读取”，不需要重新编码
- **保留注意力信息**：KV Cache 中不仅包含内容，还包含模型对不同 Token 的注意力权重——哪些部分更重要、哪些部分可以忽略——这些信息在文本形式中会丢失
- **可分析**：通过分析 KV Cache，可以理解模型到底记住了什么、对哪些 Token 注意力更集中
- **可优化**：可以从 KV Cache 中提取信号来优化模型未来的行为，而不仅仅是被动存储



图 9: Agent 记忆管理的范式对比：传统文本记忆 vs 模型原生（KV Cache）记忆⁷

8.3 从”记下来”到”理解记忆”

江鋆晨描绘了一个更远的愿景——KV Cache 不只是拿来省的，还能拿来”理解模型”：

⁷ 视频画面时间区间：01:40:00-01:50:00。

KV Cache 的长期愿景

“你存下来的是记忆，除了复用，你还能做什么别的？你可以去理解一下它记忆里面是什么东西——模型到底记住了什么，模型到底对哪些 Token 注意力更集中，哪些 Token 它觉得更重要。甚至你还可以去优化它的记忆，让它以后的行为可以更好。”

这意味着 LMCache 的未来定位不只是“KV Cache 存储公司”，而是一个“帮助大家理解大模型本身工作原理”的公司——从存储到洞察，这是一条从工程到科学的升维路径。

8.4 章末小结

Agent 时代的到来使得记忆管理从一个“优化问题”升级为“架构问题”。当模型需要在长时间、多轮交互中保持一致的认知状态时，仅靠外部文本记忆是不够的——模型需要的是原生格式的、保留注意力信息的记忆。KV Cache 的复用和优化，构成了这一新型记忆管理的技术基础。

9 创业：融资、团队与现实扭曲力场

9.1 2000 万美金融资背后的信号

TensorMesh 最近刚完成了 2000 多万美元的融资，投资方包括 NVIDIA 和 AMD。在通常的商业逻辑里，两家互相竞争的公司同时投资同一家创业公司是极不寻常的。江鋆晨在采访中首次公开了一个细节：

NVIDIA 和 AMD 为何同时投了 TensorMesh

“他们两家都分别觉得 KV Cache 这个技术非常有潜力，未来非常重要。我从来没有觉得 NVIDIA 对我们这个技术感兴趣和 AMD 有一点关系，AMD 对我们感兴趣也不是因为 NVIDIA 对我们感兴趣。他们都是独立意识到：KV Cache 做到最好，是可以让他们的硬件发挥最大性能的一个关键因素。”

这意味着：在硬件厂商看来，KV Cache 已经成为决定硬件效率的关键瓶颈。如果这一层做不好，GPU 的性能就无法充分发挥——无论是谁家的 GPU。

9.2 没有竞争对手时的孤独

被问及创业最大的困难时，江鋆晨给出了一个出人意料的答案：

没有对手的困境

“最大的困难其实是，如何在没有直接竞争对手的时候，给自己最大的动力去往前走。”

在学术界，有 paper deadline 驱动。在工业界，大多数公司有竞争对手驱动。但 LMCache 进入的是一个几乎没有直接竞争者的领域——这既是优势（先发、无人争抢），也是最大的挑战（没有外部压力，需要极强的内在驱动力）。

“某种程度上，这个领域应该只有你们一家公司。”——主持人这句话点出了 TensorMesh 的独特处境。

9.3 现实扭曲力场：正向解读

乔布斯的”现实扭曲力场”（Reality Distortion Field）在通常语境下是贬义词——在中国语境中常被称为”洗脑”。但江鋆晨给了它一个正向的重新定义：

现实扭曲力场的正向含义

”我们做的一件事情，是一个工业界现在还没有承认的事情。或者说，我们相信工业界即将承认但还没有承认的事情。这是需要一些勇气的。用我们一点微薄的力量去告诉大家，这件事情真的很重要——这是个很大的挑战。”

这种”扭曲现实”的本质不是欺骗，而是在共识形成之前，用自己的信念和执行力去推动一个方向。当 NVIDIA 和 AMD 各自独立地得出”KV Cache 是最重要的基础设施层”这个结论时，曾经的”扭曲”正在变成新的”现实”。



图 10: 现实扭曲力场的正向解读：在共识形成之前推动一个方向⁸

9.4 师生关系与创业团队

江鋆晨选择和学生一起创业，这在学术界并不常见。他的理由很直接：

⁸视频画面时间区间：01:50:00–02:03:00。

为什么和学生一起创业

- ”做这个项目的学生其实都快毕业了，如果不创业，这项目就做不下去了”
- ”这几个人的实力都太强了，我知道他们的实力”
- 师生之间的信任无法替代：”我相信你的技术实力，他们相信我的 Vision”
- 创业后关系变了——是平等的同事关系，但之前的合作经历建立的信任不会消失

他还补充了一个有趣的观察：他看到很多同样背景的教授创业时没找学生一起，最后都没成。虽然他强调”小数据量，没有统计意义”，但这句话暗含的判断是：做技术创业时，师生之间的技术信任是独特的竞争优势。

9.5 章末小结

TensorMesh 的创业故事包含了几个稀缺元素：两家互相竞争的芯片巨头同时投资、在一个无人竞争的领域先发、用学术信任构建创业团队。但最深层的驱动力是信念——在工业界还没有承认 KV Cache 是基础设施核心层的阶段，就敢于押注并推动这个认知成为共识。

10 未来基础设施与职业建议

10.1 OpenAI API = 新时代的 IP 层

江鋆晨在社交媒体上反复讨论的一个观点是：OpenAI API 是新时代的 IPv4。他特意强调”这跟我们公司战略没有直接关系”，但作为一个资深的网络系统研究者，这个类比揭示了对 AI 基础设施未来的深层思考：

从 IP 层到 API 层——基础设施的”细腰”结构

在互联网架构中，IP 层（特别是 IPv4）是所有应用都承认的通信接口——位于 TCP 和物理层之间的”细腰”。IP 层上做创新非常困难（IPv6 至今未能完全取代 IPv4，因为所有人都已经在用 IPv4）。

在 AI 时代，OpenAI API 的接口格式（API compatible）正在扮演相同的角色。所有模型提供商都在兼容 OpenAI 的 API 格式——就像所有网络应用都兼容 IP 协议。一旦这个格式稳定下来，它将成为 AI 生态系统中不可撼动的”细腰”：

- **在 API 层之上**：应用可以百花齐放，用任何模型的 API
- **在 API 层之下**：每个模型厂商可以在自己的技术栈上创新
- **API 层本身**：一旦稳定，很难被取代——即使有更好的替代方案（就像 IPv6 之于 IPv4）

10.2 不同年龄段的职业建议

江鋆晨为不同年龄段的人给出了具体建议：

- **20 岁（学生/新人）**：去找你能接触到的最好的环境——去最好的公司、最好的实验室。在这个阶段，”跟谁一起工作”比”做什么”更重要。

- **25 岁（职业起步期）**：给自己最大的挑战。去 Startup 或去当时最前沿的公司（如今年的 OpenAI），机会成本最低的时候去冒险。
- **30 岁（有积累期）**：如果有机会，和志同道合的人一起做一件大事。”我不是说一定要创业——你可以在公司里做一个大家不一定看得上的东西，可以在学术界做一个没有那么多相信的方向，或者自己创业做一个真的有潜力但不是那么多人看好的事情。”
- **对所有人的忠告**：在 AI 时代、Agent 时代，人与人之间的信任反倒成了最珍贵的东西。一个人走得快，一群人走得远。



图 11: 不同年龄段的职业建议：寻找能发挥最大价值的阶段⁹

10.3 章末小结

从 Open AI API 的”IP 层”类比，到分年龄的职业建议，江鋆晨展示了一种以网络系统思维看待世界的方式。技术架构的演变有其底层规律——从 IP 到 API，从互联网到 AI 基础设施，结构总是在重复。而个人职业发展，同样是”在正确的时间做正确的结构性选择”。

11 总结与延伸

11.1 讲者的核心脉络

江鋆晨在整个对话中展示了一条清晰的叙事线：

1. **学术选择**：从数学竞赛到姚班到 CMU——每一次选择都是”去找更大的空间”
2. **研究模式**：从工业界获取真实问题 → 在学术界做系统化研究 → 以开源和创业推动落地

⁹视频画面时间区间：02:03:00-02:20:00。

3. **范式跳转**：从视频流媒体到 KV Cache——看到了完全相同的”Internet Moment” 结构
4. **核心信念**：KV Cache 不仅是存储优化工具，更是模型的”记忆层”——一种可管理、可分析、可优化的新资产类型
5. **创业实践**：在无人竞争的领域先发，用信念推动共识，用信任构建团队

11.2 结构化的核心洞察

从这场对话中可以提炼出几个跨领域的核心命题：

KV Cache 的三大命题

命题一（工程命题）：模型推理中 90% 的算力投入在 Prefill（输入处理），而大多数硬件优化集中在 Decode（输出生成）。KV Cache 通过复用 Prefill 的中间结果，直接命中算力分配的结构性矛盾。

命题二（架构命题）：KV Cache 需要成为一个强解耦的独立层（Layer），从推理引擎和存储介质之间分离出来，在开源生态中形成标准。

命题三（愿景命题）：KV Cache 的长期价值不仅在于”省钱”——它是理解模型行为、优化模型表现的关键数据资产。模型原生记忆的管理，将成为 Agent 时代的基础设施。

11.3 职业判断力的底层逻辑

判断力的三个层次

第一层——识别模式：看历史以理解规律（读科学史），看底层变量以理解结构（宽带普及 → 流媒体爆发，计算成本下降 → LLM 爆发）

第二层——放弃的勇气：像 Ion Stoica 那样在最高潮时离开一个领域。最难的不是选择做什么，而是选择不做什么。

第三层——推动共识：在某个方向被工业界广泛承认之前，用自己的信念和执行力去推动它——这就是”现实扭曲力场”的正向含义。

11.4 拓展阅读

- Efficient Memory Management for Large Language Model Serving with PagedAttention (vLLM 论文，首次系统化提出 KV Cache 的 Page 化管理方案)
- FlexGen: High-Throughput Generative Inference of Large Language Models with a Single GPU (探讨了 KV Cache 在受限硬件下的存储-计算权衡)
- LMCache 开源仓库可在 GitHub 上查找 `lmcache` 项目
- 关于 Ion Stoica 的学术生涯和”放弃的艺术”，可参考 Spark 诞生历程的相关文章