

课程笔记

课程笔记：算法还是 Infra？硅谷一线解读

五道口纳什 & Codex

2026 年 7 月 18 日



视频作者/频道：Bilibili

发布日期：2025 年

视频时长：45 分 36 秒

视频链接：<https://www.bilibili.com/video/BV1HViYBJEsg/>

目录

1 算法与 Infra——不同优化层的一体两面	2
1.1 核心洞察：从问题出发，反向推导	2
1.2 MLC：算法与系统交汇的典范	2
1.3 看看顶尖人物的轨迹	2
1.4 本章小结	2
2 职业选择：产品还是 Infra?	3
2.1 两种路径的本质差异	3
2.2 招聘市场的残酷现实	3
2.3 创业视角：端到端能力是底线	4
2.4 本章小结	4
3 PhD 方向选择：信噪比与时机判断	4
3.1 最危险的策略：追当前最火的方向	4
3.2 “隔壁王阿姨”信号：已变现，不是信号	4
3.3 PhD 中期 Pivot 是可行的	5
3.4 地理信息差：硅谷比新加坡早一个节拍	5
3.5 不超过 5 年的判断	5
3.6 本章小结	5
4 未来方向：世界模型、能源与 AI 平民化	5
4.1 世界模型 (World Model)：方兴未艾	5
4.2 能源：非计算机的最佳赌注	6
4.3 AI 平民化：养猪场的启示	6
4.4 传统行业的巨大信息差	6
4.5 多智能体系统：未来的架构师角色	6
4.6 本章小结	7
5 强化学习：成熟的理论与新鲜的工程挑战	7
5.1 RL 理论发展简史	7
5.2 GRPO 的工程挑战：Reward Calibration	8
5.3 “RL as a Service”意味着什么	8
5.4 模型压缩：RL 的典型应用	9
5.5 本章小结	9
6 Infra 深处：数据中心与 AI 芯片	9
6.1 不是简单的运维	9
6.2 PUE：数据中心的核心效率指标	9
6.3 AI 芯片：长期赛道与标准化趋势	10
6.4 本章小结	10

7 行业周期：计算机的“土木化”	10
7.1 计算机是新的土木工程吗?	10
7.2 平民化创造新的就业形态	11
7.3 多 Agent 系统：架构师的诞生	11
7.4 本章小结	11
8 总结与延伸	11
8.1 嘉宾的结尾讨论	11
8.2 核心主张结构化蒸馏	12
8.3 开放问题与下一步	12
8.4 拓展阅读	12

1 算法与 Infra——不同优化层的一体两面

1.1 核心洞察：从问题出发，反向推导

视频开场即点出了一个被许多人纠结的问题：算法工程师还是 Infra 工程师？几位嘉宾的核心观点出奇一致——这本质上是同一个问题的不同优化层面。

从上层来讲，模型或算法的优化，一直延伸到下层的系统优化，这些东西其实都是相通的。关键还是看你要解决什么样的问题，然后从这个问题的角度去 “walking backwards”，去想不同的优化算法和优化角度。

核心主张：优化是连续的，不是对立的

算法优化和系统优化位于同一个优化频谱的两端，而非两个互斥的领域。真正的区分不在于你做哪一端，而在于你从哪个入口切入问题。无论从算法层往下走，还是从系统层往上走，最终目标都是端到端地解决一个真实问题。

1.2 MLC：算法与系统交汇的典范

讨论中引用了机器学习编译（MLC, Machine Learning Compilation）作为典型案例。MLC 要求从业者同时具备两个维度的能力：

- **ML 知识**：理解模型的数学结构、计算图、算子语义
- **System 知识**：掌握编译器后端、内存管理、硬件适配

没有 ML 背景的纯系统工程师很难理解为什么某个算子需要特殊的编译优化；没有系统背景的纯算法工程师则无法将优化落地到实际硬件上。MLC 的成功恰恰说明，在两个领域的交界处，往往蕴藏着最大的创新机会。

1.3 看看顶尖人物的轨迹

嘉宾提到，观察行业内顶尖人物的职业轨迹是一个很有价值的方向判断方法：

参考坐标

李牧 (Mu Li)、蒋家青 (Jiaqing Jiang)、庞若明 (Ruoming Pang) 等——这些在 ML 和 System 都有标志性贡献的研究者，从职业生涯早期就展现出算法与 Infra 的双重能力，既有算法 Paper，也有 Infra Paper。这并非偶然，而是由问题本质决定的。

1.4 本章小结

算法和 Infra 不是两个互斥的职业选择，而是同一问题在不同抽象层级上的优化。MLC 是这一理念的产物，而行业顶尖人物的双重能力则是最好的旁证。关键不是选 A 还是 B，而是从你要解决的问题出发，沿着优化链条向下或向上延伸自己的能力边界。



图 1: 几位嘉宾在圆桌讨论中分享观点¹

2 职业选择：产品还是 Infra?

2.1 两种路径的本质差异

讨论将职业路径分为两个大方向：靠近产品的团队和靠近 Infra 的团队。两者各有清晰的利弊：

- **产品侧**：曝光度高，直接接触用户，能获得第一手信息和市场反馈。如果产品成功，个人价值可能获得十倍、百倍的增长。但产品失败后，积累的经验不一定可迁移。
- **Infra 侧**：工作更“苦”，曝光度低，不太站在聚光灯下。但技术积累具有**线性甚至超线性的增长特性**——日复一日的深耕不会因为某个产品的成败而清零。

Infra 的长期复利

Infra 能力的积累类似于复利曲线：它可能起步慢、初期回报低，但随着时间推移，你在系统设计、性能优化、故障排查等方面的经验会形成不可替代的护城河。产品方向的回报则更像期权——大多数产品失败，但少数成功带来的回报是指数级的。

2.2 招聘市场的残酷现实

嘉宾分享了两组极具冲击力的数字：

- **算法岗位**：一个岗位可能收到 **1:10000** 的简历比例
- **Infra 岗位**：通常只收到 **20–50** 份简历

这个差距并非短期现象，而是“持续存在，甚至还在扩大化”。算法方向的热度吸引了大量涌入者，而 Infra 方向因为门槛高、见效慢，人才供给始终相对稀缺。

¹ 视频画面时间区间：00:08:20–00:10:40。

2.3 创业视角：端到端能力是底线

从创业者的角度，嘉宾给出了一个直白到近乎残酷的判断：

作为一个创过业的人，我百分之百不会招那种只有算法能力的算法同学。在真的创业的时候，更重要的是服务客户，而不是追求什么 fancy 的算法。大多数算法都能从网上的开源拿到，你只要通过数据和各种方式把它变成产品。如果你只是把 Transformer 从 HuggingFace 拉下来做成一个模型，但没有能力把它部署到 AWS 上，那我觉得这种同学的价值非常有限。

不要做“丢包侠”

有一种风气：算法同学做出模型后直接丢给 Infra 团队说“你们去 scale 吧”，自己不 end-to-end 地 own 整个流程。职业初期也许可以这样，但到了中后期，这种工作方式会严重限制你的 skill set 和 credit 积累。你做的算法，你必须能把它部署出去。

2.4 本章小结

产品侧和 Infra 侧各有围城，没有绝对的好坏。但市场数据清楚地表明：Infra 方向竞争更小、积累更稳；产品方向则回报更高但风险也更大。无论是哪条路，端到端的交付能力——从算法设计到生产部署——都是不可或缺的底线。

本节内容来自视频字幕时间区间：00:03:00–00:10:00。

3 PhD 方向选择：信噪比与时机判断

3.1 最危险的策略：追当前最火的方向

PhD 是五年时间窗口的长周期决策。嘉宾对如何选择研究方向给出了一个重要判断原则：

赌方向的第一原则

你不能做现在最火的东西，你要做未来可能会火的东西。如果你做现在最火的东西，PhD 毕业时这个方向可能已经凉了，或者已经饱和了——所有人都在里面竞争。

具体案例：Object Detection。几年前是 CV 领域最火的方向，招一个 Scientist 能收到几百份简历。现在呢？“人均 Faster R-CNN Detector Two”，MASK R-CNN 遍地都是，发一篇 Object Detection 的文章可能连 WACV 都不一定能中。

3.2 “隔壁王阿姨”信号：已变现，不是信号

嘉宾用了一个极具画面感的比喻来说明信号与噪声的区别：

当你家隔壁的王阿姨都开始跟你讲 DeepSeek 的时候，其实就证明你已经不该搞了。已经凉了。该上船的人都上船了，该占的坑位都已经被占走了。

这不仅仅是一个玩笑。它的深层含义是：当信息穿透到完全没有专业壁垒的圈层时，所有的先发优势和时间窗口都已经关闭。这时候你听到的不是信号，而是**噪声**——或者更准确地说，是已经变现完毕的过期信号。

信号 vs 已变现信息

不要用行业顶尖 10–20 个人的行为来判断方向。那个级别的信息已经不是信号了，已经是完全的过去式，已经被他们变现了。你应该看的是：哪些方向正在被少数聪明人悄悄布局，但还没有变成大众话题。

3.3 PhD 中期 Pivot 是可行的

嘉宾也给了希望：PhD 方向不是锁死的。很多人是在博三、博四时突然把方向转到 LLM 方向，在剩下的一两年内往死里干，出来几篇 Paper，也走出了不错的出路。关键不是一开始就选对，而是保持**足够的灵活性和执行力**。

3.4 地理信息差：硅谷比新加坡早一个节拍

一个被反复提及的点：地理 proximity 对方向判断的影响。

在硅谷，GPT-3 的时候已经很多人开始嗅到这个味道了。但在新加坡，一直到 GPT-3.5 之后才会嗅到这个味道。

所以嘉宾建议：你有条件的话，每年去硅谷、深圳这些前沿地区待一段时间，找人聊一聊。这种面对面获取的“软信息”，比论文和新闻早 6–12 个月。

3.5 不超过 5 年的判断

最后一层原则：

思考的时间尺度

不要做超过 5 年以上的思考和决定。这个时代变化太快，技术在以跃迁式的方式发展。你只能在周期之内做判断——比如互联网的 2000–2008，移动互联网的 2008–2018。接下来的 3 年，你就赌你相信的方向，超过 5 年的预测没有意义。

3.6 本章小结

选择 PhD 方向的关键不在于预测最准确，而在于**避免在信息已完全公开化的领域竞争**。三个可操作的原则：(1) 不做现在最火的；(2) 用“隔壁王阿姨”测试判断信息是否已过期；(3) 保持 pivot 的灵活性，不做超过 5 年的锁定。

4 未来方向：世界模型、能源与 AI 平民化

4.1 世界模型 (World Model)：方兴未艾

在讨论“赌什么方向”时，嘉宾给出了自己的判断：

以我有限的认知，计算机行业的话，我可能比较倾向于搞世界模型。还算是个方兴未艾吧，现在还没有太多公司在搞，效果也一般。Sora 2 也出了嘛。我可能觉得世界模型还可以再搞一波，搞个两三年，搞个 3 年左右。

世界模型（World Model / Spatial Intelligence）在嘉宾看来处于典型的“已有人在做但远未成熟”的阶段——少数几家公司在探索，效果还远不能令人满意，但方向本身的空间是明确的。

4.2 能源：非计算机的最佳赌注

对于非计算机方向，能源是嘉宾的第一选择：

非计算机行业的话，那我只能选能源了。因为我开特斯拉太开心了，每天就感觉特斯拉这些电池、各种东西确实好。

这个判断背后有更深层的逻辑：算力的爆炸式增长正在遭遇能源瓶颈。全球 60 多亿人，算力池要爆掉了，老黄（NVIDIA 黄仁勋）在卖卡，但电不够用。数据中心的电力供应正在成为 AI 发展的硬约束。

4.3 AI 平民化：养猪场的启示

讨论中最令人印象深刻的案例来自一位嘉宾的妻子所在公司的经历：

有一个养猪场找到我老婆的公司，说“我想要检测这个猪的情绪”。这个东西在过去完全没有人问过。但这个老板用了 ChatGPT 之后，发现可以做这些事情，他们就有很多不一样的想法。他想要检测猪的情绪和状态，因为这样可以去有效避免大规模猪瘟。

AI 渗透正在引爆意想不到的领域

第一次 AI 浪潮（CV 时代）只触达了少量科技公司。而 ChatGPT 的出现改变了这一点——它让那些从未想过用 AI 的传统行业从业者自己产生了 AI 的想法。养猪场老板主动找上门来要求 AI 服务，这是过去 CV 从业者做梦都想不到的需求场景。

4.4 传统行业的巨大信息差

讨论延伸到传统行业与计算机行业的信息鸿沟：

- 每个行业都希望用 AI，但每个行业都欠缺计算机基本原理的使用能力
- 非计算机、非互联网领域的信息化程度“极其落后”
- 这就意味着：程序员不需要在互联网这个狭窄领域卷，而是可以用自己的基础知识进入各种不同行业——仓储、物流、农业、法律

另一个案例：嘉宾的邻居是律师，律师行业现在也被要求学习使用 ChatGPT 来替代传统的人力整理档案和资料的工作，但他们学起来很吃力。

4.5 多智能体系统：未来的架构师角色

嘉宾提出了一个富有洞察力的“暴论”：

在未来一个 Multi-Agent 系统环境下，你最终处理的问题是一个类似于供应链的问题。你有一个 pipeline，这个 agent 产生了 bottleneck，agent 之间有反馈，你可以做各种在环节中的优化——比如应该提升这块的吞吐，优化那边的算法。那可能就会出现很多当年供应链专家，现在变成了所谓的“架构师”——产品架构师，去分析产品中的 bottleneck。

多智能体系统架构师

如果将 AI Agent 视为供应链中的节点，那么优化多 Agent 系统的运行效率——包括负载均衡、瓶颈检测、吞吐优化、反馈回路调优——将成为一个全新的专业领域。这个角色需要同时理解 AI 能力边界和系统设计原则。

4.6 本章小结

未来 3 年的方向判断：世界模型（计算机）和能源（跨界）是两个有共识的赌注。但更宏观的机会在于 AI 向传统行业的渗透——这一波 AI 浪潮的特点是**需求端主动觉醒**，传统行业从业者首次主动寻求 AI 解决方案，而非被科技公司推销。多智能体系统的出现还将催生全新的架构师角色，这可能是 Infra 能力者的下一片蓝海。



图 2: 讨论未来方向时的画面²

5 强化学习：成熟的理论与新鲜的工程挑战

5.1 RL 理论发展简史

嘉宾对强化学习的理论发展给出了一个清晰的时间线：

- **十多年前**：Richard Sutton 等学者的工作已经基本奠定了 RL 的算法理论基础。“你跟做强化学习的人聊，他们会告诉你，其实从算法层面来讲，没有太多新的东西。”
- **Deep RL 突破**：David Silver 等人的 AlphaZero、AlphaFold（最终获得诺贝尔奖）标志着 Deep Reinforcement Learning 在算法层面的最后一块拼图。
- **当前阶段**：LLM Post-training（尤其是 GRPO）的工程化应用。

²视频画面时间区间：00:32:00–00:36:00。

强化学习关键人物与作品

Richard Sutton ——强化学习之父，著作《Reinforcement Learning: An Introduction》是该领域的圣经。David Silver ——AlphaGo/AlphaZero/AlphaFold 核心作者。John Schulman ——PPO 算法共同发明人，曾任 OpenAI Co-founder，现创立新公司做 RLaaS。

5.2 GRPO 的工程挑战：Reward Calibration

GRPO (Group Relative Policy Optimization) 是当前 LLM 后训练中最热的技术之一。嘉宾指出，其挑战不在于新算法，而在于工程细节：

GRPO 的核心工程问题

在 GRPO 的 rollout 阶段，模型会产生多个 response，每个 response 被 reward model 打分。但这里有一个关键的校准问题：如何区分简单问题和复杂问题？简单问题天然容易得高分，复杂问题天然得分低。如果不做 reward calibration——即跨问题难度对 reward 进行归一化——优化方向就会被简单问题主导，模型无法在真正需要提升的复杂任务上取得进步。

用公式表达，GRPO 的优势函数可写为：

$$A(o_i) = \frac{r_i - \text{mean}(\{r_1, \dots, r_G\})}{\text{std}(\{r_1, \dots, r_G\})}$$

其中：

- G 是每个 prompt 采样的 response 数量 (group size)
- r_i 是第 i 个 response 的 reward
- 优势函数 $A(o_i)$ 是组内标准化的，天然处理了部分 calibration 问题

5.3 “RL as a Service” 意味着什么

嘉宾提到的一个极具信号意义的事件：

John Schulman——PPO 的共同发明人，从 OpenAI 的 Co-founder 变成了新公司的 Co-founder——他这周发布的第一个产品是 Reinforcement Learning as a Service。你想想，这些大佬做了一辈子、半辈子的强化学习，突然做了一个自己的新公司，第一个产品是 RL as a Service。这说明什么？这东西在理论上已经非常定型了。什么东西能变成一个 as a service？就是它太成熟了，成熟到可以标准化交付。

当 RL 变成水和电

如果一个领域能被封装成 as a service，意味着两件事：(1) 理论基础已经非常稳固，不需要你在原理层面做创新；(2) 未来的竞争将转向工程效率、成本和场景适配，而非算法突破。对从业者而言，这意味着如果你想做 RL 研究，可能需要关注的是如何将 RL “用到” 新场景，而非发明新的 RL 算法。

5.4 模型压缩：RL 的典型应用

在回答观众关于 RL 在模型压缩中应用的提问时，嘉宾给出了一个直接的技术路线：使用 GRPO 的训练 pipeline 做 Summarization（文本摘要/压缩）：

1. 对同一段长文本，用模型采样多个不同版本的摘要输出
2. 用 reward model（结合 KL divergence 等 loss function）给每个输出打分
3. 通过 GRPO 迭代 refine 模型的摘要能力

这种方法的优势在于不需要标注数据——reward model 可以是规则化的（如长度约束 + 信息保留度），也可以是训练得到的。

5.5 本章小结

强化学习的理论大厦在十年前就已基本成型，Deep RL 的 AlphaZero/AlphaFold 是算法层面的收官之作。当前 GRPO 的火热更多是工程问题——reward calibration、pipeline robustness、大规模 rollout 的效率。RL as a Service 的出现是这一判断最强的外部信号：理论成熟到可以被产品化。未来 RL 从业者的价值不在发明新算法，而在于将已成熟的 RL 框架应用到新领域。

6 Infra 深处：数据中心与 AI 芯片

6.1 不是简单的运维

当观众提出“搞计算机的可以做运维维护 GPU 数据中心”时，嘉宾给出了纠正——数据中心的复杂程度远超大多数程序员的想象。

我是做 Infra 的，LinkedIn 它的 Infra 是自己建的，我参与了很多跟 Data Center 相关的项目。这帮人非常聪明、非常厉害。我看他们设计的系统，包括怎么在未来预测算力从而提前规划线路、把数据中心扩容……并不配做一个很简单的工作。

6.2 PUE：数据中心的效率指标

嘉宾介绍了一个关键概念——PUE（Power Usage Effectiveness）：

$$PUE = \frac{\text{数据中心总能耗}}{\text{IT 设备能耗}}$$

其中：

- IT 设备能耗：GPU、CPU、存储、网络设备实际消耗的电力
- 总能耗：IT 设备 + 冷却系统（空调/水冷）+ 配电损耗 + 照明等
- 理想 PUE 接近 1.0，实际数据中心通常 1.2–1.6

冷却正在成为 AI 算力的瓶颈

从风冷到水冷的过渡不仅仅是换个冷却方式那么简单。NVIDIA B200 系列即将强制上水冷——单个机架的功耗已经超出了风冷的散热能力。这意味着数据中心的建筑结构、管道布局、供电系统都需要重新设计。这是一个涉及物理、流体力学、电气工程等多学科的复杂系统工程。

6.3 AI 芯片：长期赛道与标准化趋势

在回答“AI 芯片能搞几年”时，嘉宾的判断是乐观的：

- Token 价格将以“十分之一、百分之一”的速度持续下降——token 就是生产力
- 各家都建立了自己的芯片研发部门：Amazon 的 Trainium/Inferentia、Meta 的 MTIA、国内各家的芯片
- 芯片软件栈的研发需求将持续旺盛
- 但标准化是必然趋势——就像 LLVM 统一了 CPU 编译器后端，AI accelerator 未来也会出现类似的统一编译框架（MLC 等正在做这件事）

从 LLVM 到 ML Compiler

LLVM 的成功经验：通过统一的中间表示（IR），让前端语言和后端硬件解耦。AI 芯片的碎片化现状（每家都有自己的编译工具链）正在催生类似 ML Compiler 的统一方案。这对 Infra 工程师来说是一个信号：如果你能掌握编译器 + AI + 硬件的交叉技能，你在芯片标准化浪潮中会非常抢手。

6.4 本章小结

数据中心不是运维——它是一个需要物理、电气、流体力学等多学科协作的复杂系统工程，PUE 优化和冷却方案升级正在成为 AI 发展的物理硬约束。AI 芯片是一个长期赛道，标准化是可见的趋势，ML Compiler 方向的 Infra 人才将从中受益。

7 行业周期：计算机的“土木化”

7.1 计算机是新的土木工程吗？

这个比喻在讨论中引发了嘉宾之间最坦诚的交流之一：

我觉得不太像土木。因为土木需要大量的人力堆积和重复劳动——以后 AI 真的出来了，还有我们的事吗？没有了。不需要这种人力堆积了，不需要这种重复劳动了。

但同时，嘉宾也承认：计算机行业正在从“精英赛道”走向“大众工具”。这个过程类似于土木工程——曾经只有少数工程师能造桥，后来标准化到每个城市都有工程队。

7.2 平民化创造新的就业形态

尽管传统 CS 岗位的竞争越来越激烈（“今年毕业的同学，平均投 400 到 500 份简历才能拿到一个面试”），但 AI 的平民化也在创造全新的岗位：

新岗位的出现逻辑

当技术门槛降低时，价值从“会使用工具的人”转移到“能用工具解决领域问题的人”。你不会因为懂得怎么写 CUDA kernel 而自动变得有价值——价值取决于你能否用 AI 工具解决养猪场老板的实际问题、帮律师自动化档案整理、为物流公司优化仓储路径。

7.3 多 Agent 系统：架构师的诞生

延续之前的讨论，嘉宾详细阐述了多 Agent 系统架构师这一新角色的可能性：

你有一个 pipeline，Agent 之间产生了 bottleneck，某条链路反馈有问题——你可以做各种在这些环节中的优化。你应该提升这块的吞吐，去优化那边的算法。这就出现了很多当年的供应链专家，现在变成了这种所谓的架构师——去分析你这个产品里的 bottleneck。




图 3: 多 Agent 系统中的 pipeline 与 bottleneck——架构师需要识别并优化系统中的瓶颈节点

7.4 本章小结

计算机行业没有变成土木工程，但确实在向工具化、标准化方向演变。这意味着纯编程技巧的溢价在下降，而“用技术解决领域问题”的综合能力在上升。多 Agent 系统的出现将催生一个全新的角色——多 Agent 系统架构师——这可能是 Infra 背景者的天然优势领域。

8 总结与延伸

8.1 嘉宾的结尾讨论

在视频最后，嘉宾用一个实际问题收尾——Fine-tuning 自己的模型 vs 直接用 OpenAI API 的选择：

先用 OpenAI API 把业务逻辑跑通，因为它简单嘛，就是直接靠 API completion 就能完成。但真正的如果看到增长之后，肯定还是要 fine-tune 自己的模型来降低成本。这就是一个 trade-off。

这个建议看似具体，实际上呼应了整个讨论的核心精神：先解决端到端的问题（哪怕用最朴素的方法），然后在有正反馈的地方深耕优化。

8.2 核心主张结构化蒸馏

基于本次讨论，可以提炼出以下核心主张：

1. **算法与 Infra 的二元对立是假问题。**真正的能力坐标是“端到端交付能力”——从理解问题到落地部署的完整闭环。MLC 是这个理念的最佳注脚。
2. **职业选择的核心变量不是热度，而是人才供需比。**算法 1:10000，Infra 1:50 的数据说明一切。但长期看，产品方向的 exponential upside 也不应被忽视。
3. **方向判断的唯一可靠原则：不做现在最火的。**“隔壁王阿姨”测试是一种简单有效的信号-噪声过滤器。保持 pivot 的灵活性比一次选对更重要。
4. **AI 平民化是最大的结构性机会。**当养猪场老板主动找 AI 公司时，你看到了什么？不是技术突破，而是**需求端的觉醒**——过去从未被服务的行业正在成为 AI 的新市场。
5. **RL 理论已成熟，工程化是当前的主战场。**RL as a Service 的出现标志着 RL 从研究走向产品。价值从“发明算法”转移到“用好算法”。
6. **多 Agent 系统将创建一个新职业类别——系统架构师。**这个角色需要理解 Agent 的能力边界、系统的瓶颈分析和优化策略，是 Infra 能力的天然延伸。
7. **不做超过 5 年的判断。**技术发展是指数级的，长期预测在工程上不可靠。在 3 年窗口内做决策，保持学习和 pivot 的能力。

8.3 开放问题与下一步

讨论中留下了几个值得深入思考的开放问题：

- 世界模型的技术路径尚不清晰——Sora 2 是正确方向吗？还是需要完全不同的范式？
- Reward Calibration 在 GRPO 中的最优方案是什么？目前业界还没有共识答案。
- AI 芯片的标准化会以多快的速度到来？LLVM-for-AI 的最终形态会是怎样的？
- 多 Agent 系统的瓶颈分析方法论尚未建立——供应链管理的理论能多大程度迁移过来？
- AI 向传统行业渗透的速度，取决于传统行业的人才储备——这个缺口如何填补？

本次讨论的价值不在于给出确定答案，而在于呈现了硅谷一线从业者的真实判断框架。在信息过度饱和的时代，学会区分信号与噪声，可能比掌握任何单一技术都更重要。

8.4 拓展阅读

- Richard Sutton, 《Reinforcement Learning: An Introduction》——RL 领域的经典教材
- GRPO 原始论文: DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models
- MLC (Machine Learning Compilation)——陈天奇团队项目，ML + System 交汇的代表性工作
- John Schulman 关于 RL as a Service 的讨论